

论文大纲

基于大语言模型增强的动态图神经网络转化率预测研究：
融合 LLM 语义表示以缓解推荐系统中的延迟反馈偏差

UCL · 知识、信息与数据科学硕士

作者：刘一泽 · 导师：Arabella Sinclair

全文预计总字数（英文）：15,000–16,000 词

文本/行为序列 → LLM编码器 → 语义嵌入 → 动态图节点 → GNN+时间衰减 → CVR分数

第一章

引言

约 1,500 词

研究背景与动机

在线广告中的转化率（CVR）预测；CTR与CVR之间的建模差异；工业规模与商业价值。

问题陈述

延迟反馈导致假阴性标签偏差；现有图神经网络方法忽视了物品和用户特征中的语义信息。

研究问题（详见下方）

主要贡献

新颖的 LLM+GNN 混合框架；通过消融实验量化 LLM 的独立贡献；公开数据集上的基准测试。

论文结构

研究问题

RQ1 在动态图神经网络中，LLM 生成的语义嵌入能否在 CVR 预测上超越传统 ID 特征？

RQ2 融入 LLM 表示是否能够减轻延迟反馈偏差对模型训练的负面影响？

RQ3 LLM 增强方案与传统 GNN 方案之间的计算代价权衡如何？

☒ CVR 预测基础
DeepFM、DIN、DIEN——从浅层到深度模型的演进历程；特征交互建模范式。
☒ 延迟反馈问题【核心】
ES-DFM、DEFER、FSIW——现有方法及其局限性分析。
☒ 图神经网络在推荐系统中的应用
动态信息网络；时序图建模；时间衰减机制。
☒ 大语言模型用于推荐【核心】
UniSRec、RLMRec、TALLRec——LLM 作为编码器 vs. LLM 作为排序器；语义特征学习。
☒ 研究空白
目前尚无工作将 LLM 语义编码与动态图神经网络相结合，专门用于延迟反馈场景下的 CVR 预测。
覆盖范围：围绕以上四个子主题，约精读 15-20 篇核心文献。

☒ 整体框架概述
三阶段流水线：LLM 编码 → 动态图构建 → 基于 GNN 的 CVR 预测。须附架构示意图。
☒ 阶段一：LLM 语义编码【核心】
预训练模型选型（BERT / sentence-transformers）；对物品文本与用户行为序列进行编码；嵌入维度与归一化处理。
☒ 阶段二：动态图构建
节点定义（用户、物品）；边定义（带时间戳的交互行为）；时间切片图快照；将 LLM 嵌入作为节点特征注入图中。
☒ 阶段三：基于 GNN 的预测【核心】
图卷积层设计；用于缓解延迟反馈的时间衰减权重函数；聚合层与输出 MLP，最终输出 CVR 得分。
☒ 训练策略
损失函数（二元交叉熵）；小批量训练中的延迟标签处理；优化器（Adam）；正则化。
☒ 理论支撑
为何 LLM 的语义特征能与 GNN 的结构特征形成互补；从信息论角度进行阐释。
技术流水线：文本/行为序列 → LLM编码器 → 语义嵌入 → 动态图节点特征 → GNN+时间衰减 → CVR分数

第四章 实验设置		约 2,000 词
☒ 数据集		
Amazon Review（主数据集，文本特征丰富）；AliCCP（辅数据集，包含真实延迟反馈标签）；数据预处理步骤。		
☒ 对比基线		
传统方法：DeepFM、DIN；图神经网络方法：DGNN / SURGE；纯 LLM 方法：sentence-BERT 特征 + MLP（无图结构）。		
☒ 评估指标		
AUC（主指标）；对数损失（Log Loss）；分组 AUC（GAUC）；推理延迟（ms/样本）。		
☒ 实现细节		
Python 3.10、PyTorch 2.x、PyTorch Geometric、HuggingFace Transformers；GPU 环境：Colab A100；超参数搜索空间。		
☒ 可复现性		
随机种子固定；数据集划分比例（7:1:2）；代码公开发布计划。		
第五章 实验结果与分析		约 3,000 词
☒ 主实验结果		
对比表格：本文模型与所有基线在两个数据集上的 AUC 与 Log Loss 对比。		
☒ 消融实验【核心】		
变体一：去除 LLM 嵌入（仅使用 ID 特征）；变体二：去除时间衰减（标准 GNN）；变体三：去除图结构（LLM + MLP）——逐一量化每个模块的独立贡献。		
☒ LLM 编码器对比		
BERT-base vs. sentence-transformers vs. 领域微调版本；不同编码器对下游 AUC 的影响。		
☒ 延迟反馈敏感性分析		
在不同延迟窗口（1小时、6小时、24小时、7天）下的性能变化；LLM 是否在延迟更长时帮助更大？		
☒ 效率分析		
训练时间、推理延迟、内存占用与基线对比；帕累托权衡图（性能 vs. 效率）。		
☒ 案例分析 / 定性分析		
LLM 嵌入改变预测结果的典型物品举例；图上的注意力权重可视化。		

第六章	讨论	约 1,500 词
☒ 研究发现解读		
逐一回答各研究问题；LLM 在什么场景下有效，什么场景下效果有限？		
☒ 与相关工作对比		
与 UniSRec、RLMRec 等结果的横向比较；本文对领域的推进之处。		
☒ 研究局限性		
LLM 推理的计算成本；对数据集文本质量的依赖；单领域评估的泛化问题。		
☒ 未来工作展望		
在领域数据上对 LLM 进行微调；跨领域迁移学习；面向实时服务的推理优化。		
第七章	结论	约 500 词
☒ 贡献总结		
☒ 对 LLM 增强推荐系统的更广泛启示		
☒ 结语		
全文预计总字数（英文）：15,000–16,000 词。		